

LAPORAN ANALISIS KLASIFIKASI:

Memprediksi Genre Musik dari Fitur Audio

Disusun oleh: Tsaabitah Arga Nitibaskara

1. Tujuan Utama Analisis

Tujuan utama dari analisis ini adalah untuk **menginterpretasi** dan **memprediksi** genre sebuah lagu berdasarkan fitur-fitur audio teknisnya.

Bagi stakeholder (misalnya, platform streaming musik), model ini memberikan dua manfaat:

1. **Prediksi (Manfaat Bisnis):** Kemampuan untuk secara otomatis mengkategorikan jutaan lagu baru yang diunggah ke platform, meningkatkan pengalaman pengguna (user experience) melalui rekomendasi dan playlist yang lebih baik.
2. **Interpretasi (Manfaat Wawasan):** Untuk pertama kalinya, kita dapat secara kuantitatif menentukan "fitur audio apa yang paling membedakan genre 'metal' dari 'jazz'?" Wawasan ini dapat digunakan oleh produser musik atau tim A&R (Artists and Repertoire).

2. Deskripsi Singkat Data

- **Dataset:** Fitur Audio Musik (Sumber: musicgenre-small.xls - Sheet1.csv)
- **Ukuran:** 18.492 lagu (baris) dan 33 fitur (kolom).
- **Variabel Target (y):** genre (10 kategori unik, termasuk 'classic pop and rock', 'jazz and blues', 'hip-hop', dll.)
- **Variabel Fitur (X):** 30+ fitur teknis, termasuk loudness, tempo, key, mode, dan 24 fitur timbre (yang menggambarkan warna suara).

3. Ringkasan Eksplorasi Data (EDA) dan Pembersihan

Analisis eksplorasi mengungkapkan tiga poin penting:

1. **Kualitas Data:** Dataset ini **tidak memiliki nilai yang hilang (missing values)**.
2. **Pembersihan Data:** Tantangan utama adalah teknis. File CSV menggunakan format non-standar (pemisah titik koma ; dan desimal koma ,). Ini telah diperbaiki selama pemuatan data untuk memastikan 27 fitur numerik (seperti loudness dan timbre) dibaca sebagai angka (float), bukan teks.
3. **Target Tidak Seimbang:** Variabel target genre sangat tidak seimbang. dance and electronica adalah genre paling umum (3.556 lagu), sementara hip-hop adalah yang paling langka (hanya 288 lagu). Ketidakseimbangan ini menjadi tantangan utama untuk

pemodelan.

4. Ringkasan Pelatihan Model Klasifikasi

Sesuai instruksi, kami melatih tiga model klasifikasi yang berbeda setelah membagi data (80% latih, 20% uji). Untuk mengatasi data yang tidak seimbang, kami menggunakan parameter `class_weight='balanced'` pada semua model.

Berikut adalah perbandingan performa mereka pada data uji (3.699 lagu), berdasarkan hasil `analysis_classification.py`:

Model	Overall Accuracy	F1-Score (Macro Avg)	F1-Score (Weighted Avg)
Decision Tree	0.4093 (40.9%)	0.41	0.42
Logistic Regression	0.4958 (49.6%)	0.47	0.51
Random Forest	0.6123 (61.2%)	0.56	0.60

Catatan: Akurasi keseluruhan (Overall Accuracy) adalah metrik sederhana, sedangkan F1-Score (Weighted Avg) lebih baik untuk data tidak seimbang. Dalam kedua kasus, Random Forest unggul.

5. Pilihan Model Final yang Direkomendasikan

Kami merekomendasikan **Random Forest** sebagai model final.

Model ini secara signifikan mengungguli model-model lainnya, dengan akurasi 11 poin persentase lebih tinggi daripada Logistic Regression. Model ini juga menunjukkan performa F1-score yang kuat untuk genre-genre utama seperti classical (0.78) dan metal (0.77). Kemampuannya sebagai *ensemble model* (kumpulan dari banyak Decision Tree) membuatnya lebih kuat dalam menangani 27 fitur numerik yang kompleks dalam dataset ini dibandingkan model linier (Logistic Regression) atau satu Decision Tree.

6. Temuan Kunci dan Wawasan (Main Drivers)

Setelah memilih Random Forest, kami menganalisisnya untuk menemukan *main drivers* (fitur pendorong utama).

Wawasan Utama: Untuk membedakan 10 genre musik, *timbre* (warna suara), *kenyaringan*,

dan *durasi* adalah fitur yang jauh lebih penting daripada *tempo* atau *kunci nada*.

Berikut adalah 15 fitur teratas yang digunakan model untuk mengklasifikasikan genre (berdasarkan output `analysis_classification_findings.py`):

	Feature	Importance
0	loudness	0.048854
2	duration	0.048840
3	avg_timbre1	0.047216
4	avg_timbre2	0.045278
8	avg_timbre6	0.043012
7	avg_timbre5	0.041746
24	var_timbre10	0.038326
5	avg_timbre3	0.037885
17	var_timbre3	0.037003
22	var_timbre8	0.036616
16	var_timbre2	0.036470
12	avg_timbre10	0.035171
6	avg_timbre4	0.034758
25	var_timbre11	0.034658
10	avg_timbre8	0.034560

Interpretasi Temuan Kunci:

- **Timbre, Loudness, & Durasi adalah Segalanya:** Temuan ini sangat jelas. Tiga kategori fitur yang paling penting adalah loudness (kenyaringan), duration (durasi lagu), dan 24 fitur timbre (warna suara, yang mengisi sisa 13 slot teratas).
- **Fitur yang Tidak Penting:** Yang sama pentingnya adalah fitur apa yang *tidak* ada di daftar ini. tempo, key (kunci nada), mode (mayor/minor), dan time_signature (ketukan) tidak masuk dalam 15 besar. Ini memberikan wawasan kuat kepada stakeholder: *'Warna suara' dan 'kenyaringan' sebuah lagu adalah prediktor genre yang jauh lebih baik daripada 'tempo' atau 'kunci nada'-nya.*

7. Saran dan Langkah Selanjutnya (Flaws & Action Plan)

Meskipun Random Forest adalah model terbaik kami, analisis kami mengungkapkan satu kelemahan (flaw) yang signifikan:

- **Kelemahan:** Model ini memiliki **Recall 0.07 (7%) untuk genre 'hip-hop'** (terlihat di output `analysis_classification.py`). Artinya, model ini gagal mengidentifikasi 93% dari semua lagu hip-hop di data uji. Ini adalah masalah serius yang disebabkan oleh

kurangnya data hip-hop (hanya 288 sampel).

- **Rencana Aksi / Langkah Selanjutnya:**

1. **Menyeimbangkan Data (Oversampling):** Sebelum melatih ulang model, kita harus menerapkan teknik *oversampling* seperti **SMOTE** (Synthetic Minority Over-sampling Technique) pada data latih. Ini akan membuat "sampel hip-hop sintetis" untuk memberi model lebih banyak data untuk dipelajari.
2. **Pengumpulan Data:** Secara bisnis, solusi jangka panjang adalah memberi label (labelling) lebih banyak lagu hip-hop untuk menyeimbangkan dataset.
3. **Model yang Lebih Kompleks:** Jika SMOTE tidak berhasil, kita dapat mencoba model *ensemble* yang lebih canggih seperti **Gradient Boosting (XGBoost)**, yang seringkali sangat baik dalam menangani data tidak seimbang.